

# **Aprendizagem Espectral em Modelos Ocultos de Markov**

**Experimentos com a nova abordagem**

Jonas Rocha Lima Amaro

# Modelos Ocultos de Markov

- Aprendizagem Espectral
- Experimentos



# Modelos Ocultos de Markov


- Exemplo inicial
- Parâmetros do Modelo
- Aplicações do Modelo



# Exemplo Inicial

## Urnas e Bolas



- Sorteio de sequências de bolas, na moda markoviana
- Processo com estados ocultos e símbolos discretos
- Quando dá para ter certeza de que urna veio cada bola?



# Exemplo Inicial


## Urnas e Bolas

- Sorteio de sequências de bolas, na moda markoviana
- Processo com estados ocultos e símbolos discretos
- Quando dá para ter certeza de que urna veio cada bola?




# Parâmetros do Modelo

- $n \in \mathbb{N}$  Número de estados ocultos




# Parâmetros do Modelo

- $n \in \mathbb{N}$  Número de estados ocultos
- $m \in \mathbb{N}$  Número de símbolos observáveis




# Parâmetros do Modelo

- $n \in \mathbb{N}$  Número de estados ocultos
- $m \in \mathbb{N}$  Número de símbolos observáveis
- $\Pi_0 \in \mathbb{R}^n$  Distribuição do estado inicial




# Parâmetros do Modelo

- $n \in \mathbb{N}$  Número de estados ocultos
- $m \in \mathbb{N}$  Número de símbolos observáveis
- $\Pi_0 \in \mathbb{R}^n$  Distribuição do estado inicial
- $O \in \mathbb{R}^{m \times n}$  Distribuição símbolos observáveis



# Parâmetros do Modelo

- $n \in \mathbb{N}$  Número de estados ocultos
- $m \in \mathbb{N}$  Número de símbolos observáveis
- $\Pi_0 \in \mathbb{R}^n$  Distribuição do estado inicial
- $O \in \mathbb{R}^{m \times n}$  Distribuição símbolos observáveis
- $T \in \mathbb{R}^{n \times n}$  Matriz transferência



# Aplicações do Modelo

- Reconhecimento de Fala
  - Símbolos observáveis são espectros da Transformada de Fourier com filtros

# Aplicações do Modelo

- Reconhecimento de Fala
  - Símbolos observáveis são espectros da Transformada de Fourier com filtros
- Modelagem de Volatilidade do PIB
  - Experimento com dados trimestrais do Japão, Reino Unido e Estados Unidos
  - Resultado: modelo passou nos testes de Hipótese Nula e Auto-correlação

# Aprendizagem Espectral

- Motivação
- Definições iniciais
- Representação



# Motivação

Principais perguntas:

$$P((o_i)_{i=1}^t), P(o_t | (o_i)_{i=1}^{t-1})$$

# Motivação

Principais perguntas:

$$P((o_i)_{i=1}^t), P(o_t | (o_i)_{i=1}^{t-1})$$

# Motivação

Principais perguntas:

$$P((o_i)_{i=1}^t), P(o_t | (o_i)_{i=1}^{t-1})$$

Ideia para responder a primeira pergunta

$$A_x = T \operatorname{diag}((O_{x,i})_{i=1}^n)$$

$$P((o_i)_{i=1}^t) = \mathbf{1}^T \prod_{i=1}^t A_{o_i} \Pi_0$$

# Definições Iniciais

- Probabilidade do Símbolo  $i$  ser visto no tempo 1

$$P_1 \in \mathbb{R}^m$$

# Definições Iniciais

- Probabilidade do Símbolo  $i$  ser visto no tempo 1

$$P_1 \in \mathbb{R}^m$$

- Probabilidade da dupla  $i, j$  ser vista nos tempos 1,2

$$P_{2,1} \in \mathbb{R}^{m \times m}$$

# Definições Iniciais

- Probabilidade do Símbolo  $i$  ser visto no tempo 1

$$P_1 \in \mathbb{R}^m$$

- Probabilidade da dupla  $i, j$  ser vista nos tempos 1,2

$$P_{2,1} \in \mathbb{R}^{m \times m}$$

- Probabilidade da dupla  $i, j$  ser vista nos tempos 1,3 e  $x$  é vista na 2

$$P_{3,x,1} \in \mathbb{R}^{m \times m} \forall x \in [m]$$

# Definições Iniciais

- Probabilidade do Símbolo  $i$  ser visto no tempo 1

$$P_1 \in \mathbb{R}^m$$

- Probabilidade da dupla  $i, j$  ser vista nos tempos 1,2

$$P_{2,1} \in \mathbb{R}^{m \times m}$$

- Probabilidade da dupla  $i, j$  ser vista nos tempos 1,3 e  $x$  é vista na 2

$$P_{3,x,1} \in \mathbb{R}^{m \times m} \forall x \in [m]$$

- Matriz esquerda da SVD reduzida de  $P_{2,1}$

$$U \in \mathbb{R}^{m \times n}$$

# Representação

$$b_1 = U^T P_1 = (U^T O) \Pi_0$$

$$b_\infty = (P_{2,1}^T U)^+ P_1 = (U^T O)^{-T} \mathbf{1}$$

$$B_x = (U^T P_{3,x,1})(U^T P_{2,1})^+ = (U^T O) A_x (U^T O)^{-1} \quad \forall x \in [m]$$

# Representação

$$b_1 = U^T P_1 = (U^T O) \Pi_0$$

$$b_\infty = (P_{2,1}^T U)^+ P_1 = (U^T O)^{-T} \mathbf{1}$$

$$B_x = (U^T P_{3,x,1})(U^T P_{2,1})^+ = (U^T O) A_x (U^T O)^{-1} \quad \forall x \in [m]$$

Retornando à distribuição de probabilidade:

$$P((o_i)_{i=1}^t) = b_\infty^T \prod_{i=1}^t B_{x_t} b_1 = \mathbf{1}^T (U^T O)^{-1} \left( \prod_{i=1}^t (U^T O) A_{x_t} (U^T O)^{-1} \right) (U^T O) \Pi_0$$

# Experimentos

- Hipótese
- Metodologia
- Resultados



# Hipóteses

Da representação espectral era esperado:

- Tempo de treinamento menor
- Erro na probabilidade estimada maior

# Metodologia

## Métricas

- Média dos erros

$$\frac{\sum |\hat{p} - p|}{N}$$

# Metodologia

## Métricas

- Média dos erros

$$\frac{\sum |\hat{p} - p|}{N}$$

- Média dos erros normalizados

$$\frac{\sum |\hat{p} - p|^{1/l}}{N}$$

# Metodologia

## Métricas

- Média dos erros

$$\frac{\sum |\hat{p} - p|}{N}$$

- Média dos erros normalizados

$$\frac{\sum |\hat{p} - p|^{1/l}}{N}$$

- Tempo médio de treinamento

$$\frac{\sum t}{N}$$

# Metodologia


## Configuração

- Modelos
  - Pequeno: 4 estados; 8 símbolos
  - Médio: 20 estados; 40 símbolos
  - Grande: 50 estados; 100 símbolos

# Metodologia

## Configuração



- Modelos
  - Pequeno: 4 estados; 8 símbolos
  - Médio: 20 estados; 40 símbolos
  - Grande: 50 estados; 100 símbolos



# Metodologia




## Configuração

- Modelos
  - Pequeno: 4 estados; 8 símbolos
  - Médio: 20 estados; 40 símbolos
  - Grande: 50 estados; 100 símbolos




# Resultados

## Tempo




# Resultados

## Erro Médio



# Resultados

## Erro Médio Normalizado



# Considerações Finais

- Probabilidades negativas

# Considerações Finais

- Probabilidades negativas
- Comparação exclusivamente com triplas

# Considerações Finais

- Probabilidades negativas
- Comparação exclusivamente com triplas
- Avaliar comportamento com processos que não atendem o critério  $\Pi_0 > 0$

# Considerações Finais

- Probabilidades negativas
- Comparação exclusivamente com triplas
- Avaliar comportamento com processos que não atendem o critério  $\Pi_0 > 0$
- Analisar outros critérios de erro

# Referências

- L.R. Rabiner. “A tutorial on hidden Markov models and selected applications in speech recognition”. Em: Proceedings of the IEEE 77.2 (1989), pp. 257–286. doi: [10.1109/5.18626](https://doi.org/10.1109/5.18626).
- R. Bhar e S. Hamori. “Hidden Markov Models: Applications to Financial Economics”. Springer New York, NY (2004), pp. 29-40. doi: [10.1007/b109046](https://doi.org/10.1007/b109046)
- Daniel Hsu, Sham M. Kakade e Tong Zhang. “A spectral algorithm for learning Hidden Markov Models”. Em: Journal of Computer and System Sciences 78.5 (2012). JCSS Special Issue: Cloud Computing 2011, pp. 1460–1480. issn: 0022-0000. doi: <https://doi.org/10.1016/j.jcss.2011.12.025>. url: <https://www.sciencedirect.com/science/article/pii/S0022000012000244>.