

Aprendizagem Espectral em Modelos Ocultos de Markov

Jonas Rocha Lima Amaro

Instituto de Matemática Pura e Aplicada

Resumo

Modelos Ocultos de Markov são modelos versáteis para representar processos estocásticos e com isso, muitas perguntas podem ser feitas a cerca do processo partindo dos parâmetros do modelo. Neste trabalho, o leitor será introduzido à abordagem discreta de Modelos Ocultos de Markov e também à uma forma eficiente de resolver dois problemas: Calcular probabilidades de sequências; e calcular probabilidade da próxima observação dada a sequência de observações que o antecede. Finalmente, apresentaremos estudos comparativos que trazem em média uma redução de XX% no tempo a execução de rotinas se comparada à implementação mais comum.




Figura 1: Diagrama de estados.

Introdução

Cadeia de Markov

Uma *Cadeia de Markov* é um processo estocástico no qual a probabilidade do próximo evento depende apenas do evento anterior. Neste trabalho focaremos apenas em modelos de tempo e estado discretos.

por um conjunto de estados E , $|E| = n \in \mathbb{N}$ e uma matriz transição $T \in \mathbb{R}^{n \times n}$ que relaciona cada estado de partida a uma probabilidade para o estado de chegada. É, por tanto, uma representação de fenômenos em séries de tamanhos variados de forma discreta cuja a probabilidade do estado seguinte só depende do estado atual

$$P(E_{t_{i+1}}|E_{t_1}, \dots, E_{t_i}) = P(E_{t_{i+1}}|E_{t_i})$$

Por exemplo, considere um processo que cria

sequências aleatórias de letras

ABCABACCACAB
BACABACAAC
BBABAAAACCACABABABAC

Para recuperar os estados, observe que, há no total que 20 ocorrências da letra A, 11 de B, e 11 de C, calculando cada probabilidade

$$P(A|A) = 4/20$$

$$P(B|A) = 8/20$$

$$P(C|A) = 8/20$$

$$P(A|B) = 8/10$$

$$P(B|B) = 1/10$$

$$P(C|B) = 1/10$$

$$P(A|C) = 7/9$$

$$P(B|C) = 0/9$$

$$P(C|C) = 2/9$$

Por tanto, a estimativa da matriz transição que criou tais sequências é representado por

$$\begin{pmatrix} \frac{4}{20} & \frac{8}{20} & \frac{8}{20} \\ \frac{8}{10} & \frac{1}{10} & \frac{1}{10} \\ \frac{7}{9} & 0 & \frac{2}{9} \end{pmatrix}$$

De posse desta matriz é possível descobrir o estado estacionário deste processo, ou seja, estimar a distribuição dos estados após quando a quantidade de observações vai ao infinito. Digamos Há também a possibilidade de expandir o modelo adicionando mais estados na dependência do estado seguinte, como Bishop[1] discute, mas isso vem com o custo de mais variáveis para se calcular. A medida que se adiciona 1 estado na dependência, se multiplica a quantidade de parâmetros por n , a quantidade de

estados. Este nível de detalhamento pode tornar o modelo impraticável quando esta expansão se torna muito grande.

Modelo Oculto de Markov

Aprendizagem Espectral

Experimentos

Discussões

Referências

- [1] Christopher M. Bishop. *Pattern recognition and machine learning*/. Textbook for graduates. New York: Springer, c2006. Pp. 607–610. URL: <http://www.loc.gov/catdir/enhancements/fy0818/2006922522-t.html>.